



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE  
FACULTAD DE MATEMÁTICAS  
DEPARTAMENTO DE ESTADÍSTICA  
PRIMER SEMESTRE 2026

# EPA Fuel Economy.

---

*Eficiencia de combustible a partir de las características  
de un vehículo.*

**EYP230I/2307 - Análisis de Regresión**

**Profesor:** Eloy Alvarado    **Ayudante:** Matías A. Pineda

**Grupo 02**

**Integrantes:**  
Martín Alcántara, Gerardo Benítez, Vicente Olivares, Benjamín Vásquez

**Fecha de entrega:** 27 de mayo de 2026



## Índice de contenido

|                                                 |           |
|-------------------------------------------------|-----------|
| <b>1. Introducción</b>                          | <b>3</b>  |
| 1.1. Contexto . . . . .                         | 3         |
| <b>2. Análisis exploratorio de los datos</b>    | <b>3</b>  |
| 2.1. Descripción de los datos . . . . .         | 3         |
| 2.2. Limpieza de datos . . . . .                | 6         |
| 2.3. Análisis de correlación . . . . .          | 9         |
| <b>3. Plan de modelos</b>                       | <b>10</b> |
| <b>4. Modelación e Inferencia</b>               | <b>12</b> |
| <b>5. Diagnostico de modelos</b>                | <b>14</b> |
| 5.1. Selección . . . . .                        | 14        |
| 5.2. Significancia de los estimadores . . . . . | 14        |
| 5.3. Multicolinealidad . . . . .                | 15        |
| 5.4. Relevancia de los coeficientes . . . . .   | 16        |
| <b>6. Interpretación y Análisis</b>             | <b>16</b> |
| <b>7. Propuesta</b>                             | <b>16</b> |
| <b>8. Conclusión</b>                            | <b>16</b> |
| <b>9. Referencias bibliográficas</b>            | <b>17</b> |
| <b>10. Anexo</b>                                | <b>18</b> |
| 10.1. Repositorio . . . . .                     | 18        |
| 10.2. Apéndice . . . . .                        | 18        |

## Índice de tablas

|                                                                                                 |    |
|-------------------------------------------------------------------------------------------------|----|
| 1. Variables del modelo . . . . .                                                               | 4  |
| 2. Recodificación de la variable <code>drive</code> . . . . .                                   | 6  |
| 3. Recodificación de la variable <code>atvType</code> . . . . .                                 | 7  |
| 4. Observaciones con valores nulos en variables inesperadas . . . . .                           | 7  |
| 5. Categorías originales de <code>trany</code> y su clasificación . . . . .                     | 8  |
| 6. Distribución de observaciones por grupo de cilindrada ( <code>displ_grupo</code> ) . . . . . | 9  |
| 7. Comparativa de los tres modelos propuestos . . . . .                                         | 13 |
| 8. Análisis de VIF para modelo <b>M0</b> . . . . .                                              | 15 |
| 9. Análisis de VIF para modelo <b>M0</b> . . . . .                                              | 16 |
| 10. Variables eliminadas durante la limpieza de datos . . . . .                                 | 18 |



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE  
FACULTAD DE MATEMÁTICAS  
DEPARTAMENTO DE ESTADÍSTICA

## Índice de figuras

|    |                                                                                 |    |
|----|---------------------------------------------------------------------------------|----|
| 1. | Matriz de correlación de Pearson entre variables numéricas principales. . . . . | 10 |
|----|---------------------------------------------------------------------------------|----|



# 1. Introducción

## 1.1. Contexto

Los automóviles son máquinas extremadamente complejas que transforman combustible en movimiento a través de motores. Esta transformación depende de la eficiencia de los vehículos, es decir, de cuánto combustible requieren para mover el vehículo cierta distancia o, en nuestro caso, cuánta distancia recorren por unidad fija de combustible, medida en millas por galón. Es evidente que un consumidor quiera saber qué características de un vehículo afectan más el rendimiento, ya sea para bien o para mal. Además, sabemos —por razones que discutiremos a continuación— que la cilindrada del motor es uno de los mejores indicadores del rendimiento de un vehículo. Los avances tecnológicos a través de los años también han contribuido a aumentar la eficiencia, y por estas dos razones creemos que la relación entre la cilindrada y el rendimiento depende del año del vehículo. Por ello, buscaremos investigar cuánto ha afectado el avance tecnológico el rendimiento de los autos. Adicionalmente, nos interesa comparar la eficiencia media entre fabricantes y, en el caso de modelos populares con décadas de historial de producción —como el Toyota Corolla, el Honda Civic o el Volkswagen Golf—, analizar cómo ha evolucionado su rendimiento a lo largo del tiempo.

Para entender el razonamiento detrás de nuestras aseveraciones, es necesario revisar los factores que afectan el rendimiento de un vehículo. Los más importantes suelen ser las características del motor: la cilindrada, que es el volumen total de las cámaras de combustión de los cilindros, y también el número de cilindros. Generalmente los motores se componen de varios cilindros; en los datos de este modelo el mínimo es 2, y como el volumen total es la suma de los volúmenes individuales, un vehículo con más cilindros tiende a tener mayor cilindrada. Para entender por qué más volumen implica más consumo, hay que introducir el concepto de mezcla: para que se produzca combustión se requieren combustible y oxígeno, y la relación entre ambos tiene una razón ideal de aproximadamente 15 partes de aire por 1 parte de combustible. Para mantener esa mezcla en motores de mayor volumen, se consume más combustible por ciclo, lo que reduce la eficiencia.

# 2. Análisis exploratorio de los datos

## 2.1. Descripción de los datos

El análisis comienza con una descripción de los datos disponibles para este trabajo. Primero se presentan las variables incluidas en el modelo y cómo afectan positiva o negativamente la eficiencia de un vehículo. Debido a la gran cantidad de variables presentes en los datos, las descartadas no serán explicadas en detalle, pero se listan en el apéndice junto con la razón de su exclusión.



**Tabla 1**  
*Variables del modelo*

| <b>Variable</b>                                         | <b>Tipo</b> | <b>Descripción</b>                                                                                                                                 |
|---------------------------------------------------------|-------------|----------------------------------------------------------------------------------------------------------------------------------------------------|
| <i>Variable respuesta</i>                               |             |                                                                                                                                                    |
| comb08                                                  | Numérica    | Rendimiento combinado (55 % ciudad + 45 % carretera) en MPG para vehículos convencionales e híbridos, y en MPGe para PHEVs.                        |
| <i>Predictores numéricos</i>                            |             |                                                                                                                                                    |
| displ                                                   | Numérica    | Cilindrada del motor en litros. A mayor cilindrada, mayor consumo por ciclo.                                                                       |
| year                                                    | Numérica    | Año del modelo. Refleja mejoras tecnológicas acumuladas y estándares CAFE progresivamente más estrictos.                                           |
| gears                                                   | Numérica    | Número de velocidades de la transmisión. NA para CVT.                                                                                              |
| co2TailpipeGpm                                          | Numérica    | Emisiones de CO <sub>2</sub> en gramos por milla. Consecuencia directa del consumo; no incluida como predictor.                                    |
| <i>Predictores binarios</i>                             |             |                                                                                                                                                    |
| tCharger                                                | Binaria     | Turbocompresor presente (1) o no (0).                                                                                                              |
| sCharger                                                | Binaria     | Supercompresor presente (1) o no (0).                                                                                                              |
| startStop                                               | Binaria     | Tecnología start-stop presente (1) o no (0).                                                                                                       |
| <i>Predictores categóricos (dummies)</i>                |             |                                                                                                                                                    |
| drive_FWD                                               | Binaria     | Tracción delantera. Categoría de referencia: 4WD/AWD.                                                                                              |
| drive_RWD                                               | Binaria     | Tracción trasera. Categoría de referencia: 4WD/AWD.                                                                                                |
| transType_CVT                                           | Binaria     | Transmisión CVT. Categoría de referencia: Automático.                                                                                              |
| transType_Manual                                        | Binaria     | Transmisión manual. Categoría de referencia: Automático.                                                                                           |
| displ_grupo                                             | Categórica  | Cilindrada agrupada en rangos {0-2L, 2-3L, 3-4L, 4-5L, 6-7L, 7L+}. Categoría de referencia: 0-2L. Usada en M1 como alternativa categórica a displ. |
| <i>Variables auxiliares (no incluidas en el modelo)</i> |             |                                                                                                                                                    |
| atvType                                                 | Categórica  | Tecnología del vehículo: Gasoline, Diesel, FFV, Hybrid, Plug-in Hybrid. Usada para filtrado.                                                       |
| make                                                    | Categórica  | Fabricante.                                                                                                                                        |
| model                                                   | Categórica  | Nombre del modelo.                                                                                                                                 |
| cylinders                                               | Numérica    | Número de cilindros. Altamente correlacionado con displ; se usa para la creación de la variable $displ_{per\ cyl\ necesariapara M_2}$ .            |



A continuación se describen las demás variables de la tabla anterior. La inducción de aire al motor puede realizarse de tres maneras. La más común es la inducción natural, donde el aire entra a presión atmosférica. Para aumentar el rendimiento se han desarrollado dos tipos de inducción forzada, que introducen aire a mayor presión: los turbocargadores, que aprovechan la energía de los gases de escape para girar una turbina, y los supercargadores, que están mecánicamente vinculados al motor y usan su propia energía de rotación para comprimir el aire. En ambos casos, la inducción forzada permite inyectar más oxígeno en cada cilindro, lo que posibilita quemar más combustible y generar más potencia. El beneficio real para la eficiencia proviene de poder usar un motor más pequeño con inducción forzada para obtener la misma potencia que uno más grande de aspiración natural, aprovechando el menor consumo de los motores de menor cilindrada, llamado habitualmente *downsizing*.

Ahora que entendemos cómo se genera la rotación del motor, introduciremos los mecanismos que la transmiten en movimiento: el sistema de transmisión. Se identifican dos características principales: la tracción, que puede ser delantera, trasera o integral, y la caja de cambios, que puede ser manual, automática o CVT. La tracción delantera implica que el motor, la caja de cambios y el diferencial están en el mismo eje, lo que reduce el número de piezas y el peso del sistema, mejorando la eficiencia. La tracción trasera, en cambio, requiere un eje longitudinal adicional, lo que aumenta el peso y las pérdidas mecánicas, disminuyendo la eficiencia. La tracción integral es la más compleja y pesada de las tres, ya que debe distribuir la potencia a las cuatro ruedas a través de un sistema mecánico considerablemente más elaborado.

La caja de cambios es la segunda parte del sistema de transmisión. La más común en nuestro modelo es la transmisión automática, que históricamente era menos eficiente que la manual, pero que desde aproximadamente el año 2000 ha igualado e incluso superado su eficiencia, gracias al aumento sistemático en el número de velocidades disponibles, lo que permite al motor operar más tiempo en su rango óptimo de RPM. La transmisión manual, aunque era la más eficiente hasta los años noventa, ha perdido esa ventaja frente a los automáticos modernos. Por su parte, la transmisión CVT (*Continuously Variable Transmission*) prescinde de marchas fijas y varía la relación de transmisión de forma continua mediante un sistema de poleas y correa, manteniendo al motor siempre en su RPM de menor consumo. Es, en teoría, el tipo de transmisión con mayor potencial de eficiencia.

Por último, están los ATV (*Advanced Technology Vehicles*), que en nuestro modelo corresponden a vehículos convencionales a gasolina, diésel, híbridos, PHEV (*Plug-in Hybrid Electric Vehicle*) y FFV (*Flexible Fuel Vehicle*). Los vehículos convencionales, diésel y FFV siguen en general las ideas explicadas anteriormente, con algunas diferencias menores. El combustible diésel es aproximadamente un 15 % más energéticamente denso que la gasolina, por lo que en motores de igual tamaño tiende a producir mejor rendimiento. Los FFV están diseñados para operar con gasolina convencional o mezclas con etanol de hasta 85 % (E85); dado que el etanol tiene menor densidad energética, el rendimiento en E85 es inferior, pero en los datos se usa siempre el combustible principal recomendado por el fabricante. Los híbridos y los PHEVs combinan tracción eléctrica con mecánica y son siempre automáticos, ya que requieren un controlador electrónico para gestionar la distribución de potencia entre ambas fuentes; son los vehículos de combustión interna con mejor eficiencia por amplio margen. La comparación entre híbridos convencionales y vehículos tradicionales es directa, mientras que los PHEVs, al poder operar en modo completamente eléctrico, requieren considerar su métrica combinada (*phevComb* en MPGe) para una comparación justa.



Esta última categoría podría justificar un análisis separado.

## 2.2. Limpieza de datos

Para la limpieza de datos se comenzó con un análisis preliminar de las columnas según la [documentación oficial](#). Las columnas descartadas se eliminaron en dos rondas; las razones se encuentran en el apéndice. Luego de reducir el dataset de 84 descriptores a 14, se procedió a procesarlos comenzando con **tCharger**, **sCharger** y **startStop**. Estas columnas son de tipo binario, pero en los datos originales están codificadas con los valores **None**, **S**, **T** o **Y/N** para supercargadores, turbocargadores y start-stop respectivamente. Para incorporarlas al modelo de regresión se recodificaron como 0 o 1.

A continuación se procesó la variable **drive**, que representa el tipo de tracción de los vehículos. Esta columna tenía 8 categorías distintas en el dataset original, las cuales se redujeron a 3 según la siguiente tabla.

**Tabla 2**

*Recodificación de la variable **drive***

| Categoría original (EPA)   | Categoría final | <i>n</i> |
|----------------------------|-----------------|----------|
| Front-Wheel Drive          | FWD             | 15.831   |
| Rear-Wheel Drive           | RWD             | 15.771   |
| 4-Wheel or All-Wheel Drive | 4WD/AWD         | 6.645    |
| All-Wheel Drive            | 4WD/AWD         | 6.580    |
| 4-Wheel Drive              | 4WD/AWD         | 2.688    |
| 2-Wheel Drive              | Excluida        | 507      |
| Part-time 4-Wheel Drive    | Excluida        | 719      |
| NaN                        | Excluida        | 1.186    |

Las categorías **2-Wheel Drive** y **Part-time 4-Wheel Drive** fueron excluidas por ser minoritarias, corresponder en su mayoría a vehículos antiguos y no ajustarse a la clasificación estándar del modelo. Junto con los registros sin valor en **drive**, las filas eliminadas en este paso representan el 4,8 % del total de observaciones originales, por lo que el efecto sobre la representatividad es mínimo en comparación con la interpretabilidad que aporta este paso.

Para el procesamiento de **atvType** se identificaron las categorías presentes en la fuente, que se muestran en la siguiente tabla.



**Tabla 3**

*Recodificación de la variable `atvType`*

| Categoría original (EPA) | Categoría final | <i>n</i> |
|--------------------------|-----------------|----------|
| NaN                      | Gasoline        | 43.325   |
| Diesel                   | Diesel          | 1.238    |
| Hybrid                   | Hybrid          | 1.805    |
| FFV                      | FFV             | 1.538    |
| Plug-in Hybrid           | Plug-in Hybrid  | 442      |
| EV                       | Excluida        | 1.457    |
| CNG                      | Excluida        | 50       |
| FCV                      | Excluida        | 42       |
| Bifuel (CNG)             | Excluida        | 20       |
| Bifuel (LPG)             | Excluida        | 8        |
| eFCV                     | Excluida        | 2        |

Los vehículos convencionales a gasolina no tienen valor en `atvType` en los datos originales; se les asignó la etiqueta **Gasoline** para claridad. Las categorías excluidas corresponden a vehículos eléctricos puros, de gas natural, de hidrógeno o de combustible dual, que no son directamente comparables con vehículos de combustión interna en términos de MPG. En conjunto representan el 3,2 % de las observaciones originales, por lo que su exclusión tiene un efecto mínimo sobre la representatividad del dataset.

Tras completar la limpieza de las variables categóricas, se verificó si quedaban filas con valores nulos. Se encontraron 3 registros con valores faltantes en `cylinders` y/o `displ`, correspondientes a 2 modelos distintos.

**Tabla 4**

*Observaciones con valores nulos en variables inesperadas*

| Idx   | make   | model    | year | cylinders | displ | drive   | trany        |
|-------|--------|----------|------|-----------|-------|---------|--------------|
| 21410 | Subaru | RX Turbo | 1985 | NaN       | NaN   | 4WD/AWD | Manual 5-spd |
| 21411 | Subaru | RX Turbo | 1985 | NaN       | NaN   | 4WD/AWD | Manual 5-spd |
| 21500 | Mazda  | RX-7     | 1986 | NaN       | 1.3   | RWD     | Manual 5-spd |

Los tres registros tienen valores nulos en `cylinders` o `displ` por registros incompletos en la fuente EPA. El valor faltante del Mazda RX-7 (índice 21500) fue corregido manualmente consultando otros años del mismo modelo en el dataset. Los dos registros del Subaru RX Turbo (índices 21410–21411), al no contar con información suficiente para imputar, se eliminaron mediante `dropna()`.

Con los datos libres de valores faltantes y las categorías correctamente identificadas, se procedió a codificar `trany` y `drive`. La codificación de `trany` requirió un procesamiento previo, ya que esta columna combina el tipo de transmisión y el número de velocidades en un mismo campo. La Tabla 5 muestra los tipos de transmisión presentes en los datos y su clasificación.



**Tabla 5**

*Categorías originales de `trany` y su clasificación*

| Categoría original (EPA)         | Clasificación | <i>n</i> |
|----------------------------------|---------------|----------|
| <i>Manual</i>                    |               |          |
| Manual 3-spd                     | Manual        | 77       |
| Manual 4-spd                     | Manual        | 1.483    |
| Manual 4-spd Doubled             | Manual        | 17       |
| Manual 5-spd                     | Manual        | 8.392    |
| Manual 6-spd                     | Manual        | 3.138    |
| Manual 7-spd                     | Manual        | 182      |
| <i>Automático</i>                |               |          |
| Automatic 3-spd                  | Automatic     | 3.151    |
| Automatic 4-spd                  | Automatic     | 11.048   |
| Automatic 5-spd                  | Automatic     | 2.203    |
| Automatic 6-spd                  | Automatic     | 1.758    |
| Automatic 7-spd                  | Automatic     | 720      |
| Automatic 8-spd                  | Automatic     | 1.141    |
| Automatic 9-spd                  | Automatic     | 875      |
| Automatic 10-spd                 | Automatic     | 517      |
| Automatic (S4--S10)              | Automatic     | 3.705    |
| Automatic (AM5--AM8)             | Automatic     | 584      |
| Automatic (AM-S6--AM-S10)        | Automatic     | 1.300    |
| Automatic (A1), (A2)             | Automatic     | 1.495    |
| Automatic (L3), (L4)             | Automatic     | 4        |
| <i>CVT</i>                       |               |          |
| Automatic (variable gear ratios) | CVT           | 1.203    |
| Automatic (AV-S1)                | CVT           | 46       |
| Automatic (AV-S6)                | CVT           | 376      |
| Automatic (AV-S7)                | CVT           | 224      |
| Automatic (AV-S8)                | CVT           | 226      |
| Automatic (AV-S10)               | CVT           | 67       |
| NaN                              | Excluida      | 11       |

Las categorías **Automatic (SX)** corresponden a transmisiones automáticas con modo secuencial de X velocidades (cambios manuales mediante paletas o palanca). Las **AM** y **AM-S** son transmisiones automáticas de doble embrague. Las **AV** son variantes de CVT con relaciones virtuales reportadas. La clasificación se realizó según si el nombre contiene **variable gear ratios** o **AV** (CVT), comienza con **Manual** (Manual), o en caso contrario (Automático).

A partir de `trany` se extrajeron dos columnas nuevas: `transType`, con el tipo de transmisión, y `gears`, con el número de velocidades. Para las transmisiones CVT, `gears` se dejó como NaN, ya que el número de velocidades no es comparable con el de transmisiones de marchas fijas. Esto implica que posiblemente sea necesario tratar estos vehículos en una regresión separada para analizar el efecto de esta tecnología sobre la eficiencia. Algo similar podría ocurrir con los PHEVs, lo que se discutirá más adelante.

Para establecer una base común de comparación entre vehículos PHEV y convencionales, se reemplazó `comb08` por `phevComb` en los registros con `atvType = Plug-in Hybrid`. La columna `phevComb` refleja la



eficiencia en modo combinado (eléctrico y gasolina) de los PHEVs, mientras que `comb08` registra únicamente el modo convencional sin asistencia eléctrica. Dado que precisamente esa asistencia es el beneficio que caracteriza a estos vehículos y parte de lo que se busca estudiar, `phevComb` es la métrica más adecuada. Para construir las categorías descritas en la Tabla 1 para  $M1$ , se agruparon las cilindradas considerando que los vehículos con menos de 2 litros tienden a corresponder a autos económicos, y luego se fueron agrupando en intervalos de 1 litro, dejando los vehículos de más de 7 litros de cilindrada agrupados juntos, ya que estos son poco comunes. Las cantidades por grupo se resumen en la Tabla 6.

**Tabla 6**


*Distribución de observaciones por grupo de cilindrada (`displ_grupo`)*

| Grupo | $n$   | %     |
|-------|-------|-------|
| 0–2L  | 11447 | 24.9  |
| 2–3L  | 14334 | 31.2  |
| 3–4L  | 8629  | 18.8  |
| 4–5L  | 5557  | 12.1  |
| 5–6L  | 4497  | 9.8   |
| 6–7L  | 1487  | 3.2   |
| 7L+   | 61    | 0.1   |
| Total | 46012 | 100.0 |

Finalmente, se codificaron `transType` y `drive` como variables dummy. Tras eliminar `trans` y `phevComb`, el dataset quedó con las 16 columnas presentadas al inicio del análisis exploratorio. Cabe mencionar que `make` y `model` no fueron codificadas, ya que generarían más de 1.000 variables dummy dado el número de marcas y modelos distintos presentes en los datos. Se optó por mantenerlas durante todo el proceso de limpieza para conservar la trazabilidad de los registros excluidos y porque, más adelante en la metodología, se utilizarán para agrupar o filtrar por marca y modelo en los análisis propuestos.

## 2.3. Análisis de correlación

Para evaluar colinealidad entre los predictores numéricos se calculó la matriz de correlación de Pearson (Figura 1). Se observa una correlación muy alta entre `displ` y `cylinders` ( $r = 0.90$ ), lo que indica que ambas variables capturan esencialmente la misma información sobre el tamaño del motor. Por esta razón, `cylinders` no se incluye como predictor independiente en ningún modelo, sino que se utiliza únicamente para construir `displ_per_cyl` (Modelo  $M_2$ ), cuya correlación con `cylinders` es considerablemente menor ( $r = 0.39$ ).



**Imagen 1**

*Matriz de correlación de Pearson entre variables numéricas principales.*

### 3. Plan de modelos

Para llevar a cabo el análisis propuesto en la pregunta de investigación, decidimos proponer 3 modelos candidatos. Estos modelos los construimos a partir del análisis y conocimiento previamente descritos sobre este tema, y buscan, con la información disponible, definir de 3 maneras distintas el fenómeno que queremos estudiar.

Estos modelos son los siguientes:



$$\begin{aligned} M_0 : \text{comb08} = & \beta_0 + \beta_1 \text{displ} + \beta_2 \text{year} + \beta_3 (\text{displ} \cdot \text{year}) \\ & + \beta_4 \text{gears} + \beta_5 \text{tCharger} + \beta_6 \text{sCharger} + \beta_7 \text{startStop} \\ & + \beta_8 \text{FWD} + \beta_9 \text{RWD} + \beta_{10} \text{Manual} + \epsilon \end{aligned}$$

$$\begin{aligned} M_1 : \text{comb08} = & \beta_0 + \beta_1 \text{displ}_{2-3L} + \beta_2 \text{displ}_{3-4L} + \beta_3 \text{displ}_{4-5L} \\ & + \beta_4 \text{displ}_{5-6L} + \beta_5 \text{displ}_{6-7L} + \beta_6 \text{displ}_{7L+} + \beta_7 \text{year} \\ & + \beta_8 (\text{displ}_{2-3L} \cdot \text{year}) + \beta_9 (\text{displ}_{3-4L} \cdot \text{year}) + \beta_{10} (\text{displ}_{4-5L} \cdot \text{year}) \\ & + \beta_{11} (\text{displ}_{5-6L} \cdot \text{year}) + \beta_{12} (\text{displ}_{6-7L} \cdot \text{year}) + \beta_{13} (\text{displ}_{7L+} \cdot \text{year}) \\ & + \beta_{14} \text{gears} + \beta_{15} \text{tCharger} + \beta_{16} \text{sCharger} + \beta_{17} \text{startStop} \\ & + \beta_{18} \text{FWD} + \beta_{19} \text{RWD} + \beta_{20} \text{Manual} + \epsilon \end{aligned}$$

$$\begin{aligned} M_2 : \text{comb08} = & \beta_0 + \beta_1 \text{displ\_per\_cyl} + \beta_2 \text{year} + \beta_3 (\text{displ\_per\_cyl} \cdot \text{year}) \\ & + \beta_4 \text{startStop} + \beta_5 \text{gears} + \beta_6 \text{tCharger} + \beta_7 \text{sCharger} \\ & + \beta_8 \text{RWD} + \beta_9 \text{FWD} + \beta_{10} \text{Manual} + \epsilon \end{aligned}$$

Para todos los modelos dejamos fuera las variables auxiliares de la Tabla 1. El modelo  $M_0$  representa la versión más simple de nuestros supuestos: incluye las variables identificadas en el EDA como relevantes para la eficiencia de un vehículo, junto con la interacción  $\text{displ} * \text{year}_c$ , que captura nuestra pregunta central — si la mejora de eficiencia en el tiempo difiere según el tamaño del motor.

El modelo  $M_1$  representa la misma idea, pero en lugar de utilizar la cilindrada de los vehículos de manera continua, esta se representa como categorías de segmentos de volumen del motor, como se especificó en la Tabla 1. Esta decisión se tomó dado que la distribución de  $\text{displ}$  está altamente concentrada en motores de hasta 4L, que representan  $\approx 74.8\%$  de los datos. El problema de una especificación continua, como en  $M_0$ , es que se estima una única pendiente para  $\text{displ}$  y para su interacción con  $\text{year}_c$ , y ambas quedan dominadas por este segmento. Para poder evaluar si la linealidad global es razonable, o si hay segmentos menos representados que se comportan de manera distinta, el modelo  $M_1$  propone tratar la interacción  $\text{displ} * \text{year}_c$  de manera categórica, separada para cada categoría de cilindrada, permitiendo que cada segmento se ajuste de forma independiente a la tendencia de los vehículos más comunes.

Finalmente, el modelo  $M_2$  representa una aproximación distinta:  $\text{displ}$  mezcla dos dimensiones, la cantidad de cilindros y el volumen por cilindro, las cuales están altamente correlacionadas ( $r = 0.90$ , Figura 1), por lo que no pueden incluirse como predictores independientes sin generar colinealidad severa. Para aislar el tamaño por cilindro, se construye la variable  $\text{displ\_per\_cyl} = \text{displ}/\text{cylinders}$ , interactuada con  $\text{year}_c$ . Esto permite evaluar si la tendencia temporal en eficiencia se explica mejor por el tamaño promedio de cada cilindro —dimensión asociada a la tendencia de *downsizing* con inducción forzada— que por la cilindrada total o agrupada.



## 4. Modelación e Inferencia

Con el fin de verificar las hipótesis planteadas por los tres modelos, se desarrolla y ejecuta un script de R. En particular, los modelos de regresión de la forma  $Y \sim X\beta + \varepsilon$  se trabajan con la función `lm` propia del lenguaje. Por ejemplo, un modelo  $M_\varphi : \text{comb08} = \beta_0 + \beta_1 \text{displ}$ , según los datos `df_filtered`, se ejecutaría con el comando `lm(comb08 ~ displ, data = df_filtered)`.

Los resultados de los tres modelos se resumen en la Tabla 7. En particular, notamos que todos los coeficientes resultan significativos. Esto se ve explicado, principalmente, por el elevado número de datos utilizados en el cálculo de la regresión. Se realiza un estudio más detallado en las secciones posteriores.

Cabe destacar que para todos los modelos se centraron los años. Esto se hace para controlar el efecto arbitrario generado por el año absoluto. En particular, se observaba una correlación muy elevada entre las variables `displ`, con `displ:year` (y sus respectivas formas en los modelos **M1** y **M2**, debido a que `displ:year`  $\approx 2000\text{displ}$ ).



**Tabla 7**

*Comparativa de los tres modelos propuestos*

|                                | M0         | M1         | M2           |
|--------------------------------|------------|------------|--------------|
| <i>Estimadores compartidos</i> |            |            |              |
| (Intercept)                    | 24.989*    | 22.683*    | 29.110*      |
| year_c                         | 0.182*     | 0.130*     | 0.283*       |
| gears                          | 0.332*     | 0.284*     | 0.038+       |
| tCharger                       | -1.084*    | -1.716*    | -0.457*      |
| sCharger                       | -0.622*    | -0.948*    | -1.254*      |
| startStop                      | 1.325*     | 1.234*     | 2.070*       |
| drive_FWD                      | 3.321*     | 3.165*     | 4.707*       |
| drive_RWD                      | 0.827*     | 0.746*     | 0.301*       |
| transType_Manual               | 0.572*     | 0.446*     | 1.519*       |
| <i>Efecto individual</i>       |            |            |              |
| displ                          | -2.399*    |            |              |
| displ × year_c                 | -0.027*    |            |              |
| displ_grupo2-3L                |            | -4.359*    |              |
| displ_grupo2-3L × year_c       |            | -0.011*    |              |
| displ_grupo3-4L                |            | -6.891*    |              |
| displ_grupo3-4L × year_c       |            | -0.033*    |              |
| displ_grupo4-5L                |            | -8.435*    |              |
| displ_grupo4-5L × year_c       |            | -0.088*    |              |
| displ_grupo5-6L                |            | -10.057*   |              |
| displ_grupo5-6L × year_c       |            | -0.040*    |              |
| displ_grupo6-7L                |            | -9.418*    |              |
| displ_grupo6-7L × year_c       |            | -0.180*    |              |
| displ_grupo7L+                 |            | -12.514*   |              |
| displ_grupo7L+ × year_c        |            | -0.123**   |              |
| displ_per_cyl                  |            |            | -20.049*     |
| displ_per_cyl × year_c         |            |            | -0.309*      |
| <i>Métricas</i>                |            |            |              |
| R2                             | 0.662      | 0.679      | 0.523        |
| R2 Ajustado                    | 0.662      | 0.679      | 0.523        |
| AIC                            | 222 527.0  | 220 235.6  | 237 611.6    |
| BIC                            | 222 631.3  | 220 426.8  | 237 715.9    |
| RMSE                           | 3.045 275  | 2.966 204  | 3.615 697    |
| Número de Observaciones        | 43 929     | 43 929     | 43 929       |
| + p < 0.1                      | * p < 0.05 | * p < 0.01 | ** p < 0.001 |

Se reportan los resultados principales del análisis de varianza realizado sobre los tres modelos. En particular, se separa la tabla en tres secciones. Primero, se reportan los coeficientes asociados a estimadores presentes en los tres modelos. Segundo, se reportan los efectos específicos propuestos según cada modelo. Tercero, se reportan métricas de interés de los modelos para un análisis comparativo posterior.



## 5. Diagnostico de modelos

### 5.1. Selección

Hasta el momento, hemos trabajado con tres distintos modelos. Estos tres modelos son idénticos a excepción de la manera en que se identifica y trabaja el efecto del volumen del motor, y su relación con el año de los vehículos. En esta sección buscaremos discutir, en base a las pruebas realizadas, la pertinencia de los distintos modelos, con el objetivo de seleccionar el mejor modelo, o aquel que busquemos defender. Observando los resultados en la Tabla 7, se puede rápidamente descartar el modelo **M2**, debido a tener un desempeño notoriamente inferior en todas las métricas utilizadas. En particular, notamos que el valor de  $R_{adj}^2$  es de 0.523 para este modelo, mientras que para los modelos **M0** y **M1** se tienen valores de 0.662 y 0.679 respectivamente. Por otro lado, la comparativa entre **M0** y **M1** requiere mayor atención. En estricto rigor, el modelo **M1** tiene un mejor desempeño de manera transversal. Sin embargo, este incremento es marginal, en especial al compararlo con el modelo **M2**. Por ende, es necesario determinar si esta mejora es suficientemente significativa para justificar la reducción en la interpretabilidad de los resultados. Esto es, el modelo **M0** es tratado como valor numérico y, por ende, el valor de los coeficientes asociados a esta variable tiene una interpretación sencilla y directa en un sentido físico. Tomando como ejemplo el efecto de la columna `displ`, notamos que se obtiene un valor de  $-2.399$ . Esto es, cuando el volumen del motor aumenta en 1 litro, la eficiencia del vehículo disminuye por, aproximadamente, 2.4 millas por galón de combustible. Este nivel de interpretación se vuelve más trabajoso al utilizar el modelo **M1**. Al ser una variable categórica, el efecto asociado refiere a la tendencia que tiene según la inclusión a cierto grupo. Esto es, el coeficiente asociado a cada grupo de la tabla representa la pérdida de eficiencia al pertenecer a dicho grupo, utilizando como base el grupo de vehículos con volumen de motor menor a 2 litros. Si bien este análisis tiene sus beneficios, esto requiere un conocimiento previo mayor, y no aporta información sustancialmente distintiva, considerando que se puede observar una tendencia decreciente en los grupos, como predicho por el modelo **M0**. De esta manera, determinamos más relevante el modelo **M0**, y es con este el que buscaremos seguir trabajando.

### 5.2. Significancia de los estimadores

Como mencionado anteriormente, los estimadores observados en la Tabla 7 tienen todos un alto nivel de significancia. En particular, los resultados reportados por la tabla ANOVA nativa de R se observan, en su mayoría, como  $< 2e^{-16}$ , con algunas pocas excepciones. Esto resulta alarmante, pero es un comportamiento totalmente esperado en base al número de observaciones presentes en el análisis, debido a que el valor-p está relacionado al número de comparaciones según  $p \propto \frac{1}{\sqrt{n}}$ . En otras palabras, toda diferencia, sin importar cuan marginal pueda ser, se ve dilatada y exagerada al ser observada de manera repetida. Esto no tiene solución, debido al no ser estrictamente un error del modelo. Pero sí significa que se requiere considerar otras métricas o métodos de análisis.



### 5.3. Multicolinealidad

Recordamos que el modelo actual está dado por

$$\begin{aligned} M_0 : \text{comb08} = & \beta_0 + \beta_1 \text{displ} + \beta_2 \text{year} + \beta_3 (\text{displ} \cdot \text{year}) \\ & + \beta_4 \text{gears} + \beta_5 \text{tCharger} + \beta_6 \text{sCharger} + \beta_7 \text{startStop} \\ & + \beta_8 \text{FWD} + \beta_9 \text{RWD} + \beta_{10} \text{Manual} + \epsilon. \end{aligned}$$

Además, reiteramos que esta relación define la interacción de variables físicas, en su efecto de la eficiencia de combustible para un determinado vehículo. De esta manera, es imperativo realizar un análisis de multicolinealidad de las variables consideradas. Esto puesto que, al considerar una gran cantidad de atributos de un vehículo, sería posible que el efecto de algunas estén más correlacionadas de lo esperado. En base a ello, se realiza un análisis de VIF, cuyos resultados se observan en la Tabla 8. Notamos que, en su mayoría, los resultados no indican multicolinealidad, con la excepción de las variables asociadas al año, como se observa en la primera parte de la tabla. La segunda parte de la tabla corrobora nuestra hipótesis; al eliminar el efecto del año, se reduce la multicolinealidad del modelo. La variable **gears** aún presenta un VIF ligeramente elevado, pero se decide no intervenir para este, debido a su efecto físico en el uso eficiente del vehículo.

**Tabla 8**

*Análisis de VIF para modelo **M0***

| Coeficiente                  | VIF   |
|------------------------------|-------|
| <i>Considerando year_c</i>   |       |
| displ                        | 1.621 |
| year_c                       | 8.447 |
| gears                        | 3.986 |
| tCharger                     | 1.658 |
| sCharger                     | 1.041 |
| startStop                    | 2.102 |
| drive_FWD                    | 1.817 |
| drive_RWD                    | 1.446 |
| transType_Manual             | 1.247 |
| displ:year_c                 | 7.191 |
| <i>Sin considerar year_c</i> |       |
| displ                        | 1.617 |
| gears                        | 3.782 |
| tCharger                     | 1.598 |
| sCharger                     | 1.041 |
| startStop                    | 2.077 |
| drive_FWD                    | 1.815 |
| drive_RWD                    | 1.445 |
| transType_Manual             | 1.212 |
| displ:year_c                 | 2.752 |

Se reportan los resultados de la prueba VIF para el modelo **M0**, incluyendo y excluyendo el efecto individual del año.



## 5.4. Relevancia de los coeficientes

Hasta el momento hemos trabajado con el modelo completo incluyendo todas sus variables. Recordamos, sin embargo, que si bien los estimadores tienen alta significancia estadística, esto no nos asegura que tengan un efecto sustancial en la eficiencia final del vehículo. Para ello,

**Tabla 9**

*Análisis de VIF para modelo **M0***

| Parametro        | Coeficiente Estandarizado | Intervalo de confianza (95 %) |
|------------------|---------------------------|-------------------------------|
| (Intercept)      | 0.00                      | [0.00, 0.00]                  |
| displ            | -0.62                     | [-0.62, -0.61]                |
| year_c           | 0.43                      | [0.41, 0.45]                  |
| gears            | 0.10                      | [0.09, 0.12]                  |
| tCharger         | -0.09                     | [-0.10, -0.08]                |
| sCharger         | -0.02                     | [-0.02, -0.01]                |
| startStop        | 0.09                      | [0.09, 0.10]                  |
| drive FWD        | 0.30                      | [0.29, 0.30]                  |
| drive RWD        | 0.08                      | [0.07, 0.08]                  |
| transType_Manual | 0.05                      | [0.04, 0.06]                  |
| displ × year_c   | -0.22                     | [-0.23, -0.21]                |

Se reportan los resultados de la prueba VIF para el modelo **M0**, incluyendo y excluyendo el efecto individual del año.

## 6. Interpretación y Análisis

## 7. Propuesta

## 8. Conclusión



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE  
FACULTAD DE MATEMÁTICAS  
DEPARTAMENTO DE ESTADÍSTICA

## 9. Referencias bibliográficas

U.S. Department of Energy and U.S. Environmental Protection Agency. (2026). Fuel economy data.  
<https://www.fueleconomy.gov/feg/download.shtml>.



## 10. Anexo

### 10.1. Repositorio

La totalidad de los códigos utilizados para la limpieza de los datos, el análisis, y modelamiento, será almacenado en un [repositorio de github](#).

Este repositorio está organizado separando los datos, y códigos utilizados en su preprocesamiento en una carpeta, y los códigos asociados al análisis de regresión en otro. El desarrollo de estos códigos es de desarrollo y uso exclusivo e independiente por los integrantes del grupo, en línea a los datos de la EPA según el proyecto "Fuel Economy", para efectos académicos.

### 10.2. Apéndice

**Tabla 10**

*Variables eliminadas durante la limpieza de datos*

| Variable     | Razón    | Variable        | Razón    | Variable    | Razón    |
|--------------|----------|-----------------|----------|-------------|----------|
| city08       | <i>a</i> | combA08         | <i>b</i> | cityCD      | <i>c</i> |
| highway08    | <i>a</i> | cityA08         | <i>b</i> | highwayCD   | <i>c</i> |
| barrels08    | <i>a</i> | highwayA08      | <i>b</i> | combinedCD  | <i>c</i> |
| barrelsA08   | <i>a</i> | combA08U        | <i>b</i> | cityUF      | <i>c</i> |
| fuelCost08   | <i>a</i> | cityA08U        | <i>b</i> | highwayUF   | <i>c</i> |
| fuelCostA08  | <i>a</i> | highwayA08U     | <i>b</i> | combinedUF  | <i>c</i> |
| youSaveSpend | <i>a</i> | combE           | <i>b</i> | phevBlended | <i>c</i> |
| feScore      | <i>a</i> | cityE           | <i>b</i> | charge120   | <i>c</i> |
| ghgScore     | <i>a</i> | highwayE        | <i>b</i> | charge240   | <i>c</i> |
| ghgScoreA    | <i>a</i> | co2A            | <i>b</i> | charge240b  | <i>c</i> |
| comb08U      | <i>d</i> | co2TailpipeAGpm | <i>b</i> | c240Dscr    | <i>c</i> |
| city08U      | <i>d</i> | fuelType2       | <i>b</i> | c240bDscr   | <i>c</i> |
| highway08U   | <i>d</i> | UCityA          | <i>b</i> | range       | <i>c</i> |
| co2          | <i>d</i> | UHighwayA       | <i>b</i> | rangeCity   | <i>c</i> |
| trany        | <i>d</i> | phevCity        | <i>d</i> | rangeHwy    | <i>c</i> |
| trans_dscr   | <i>d</i> | phevHwy         | <i>d</i> | rangeA      | <i>c</i> |
| fuelType     | <i>d</i> | id              | <i>e</i> | rangeCityA  | <i>c</i> |
| fuelType1    | <i>d</i> | engId           | <i>e</i> | rangeHwyA   | <i>c</i> |
| baseModel    | <i>d</i> | mfrCode         | <i>e</i> | evMotor     | <i>c</i> |
| UCity        | <i>d</i> | createdOn       | <i>e</i> | VClass      | <i>f</i> |
| UHighway     | <i>d</i> | modifiedOn      | <i>e</i> | hlv         | <i>f</i> |
|              |          | mpgData         | <i>e</i> | hvp         | <i>f</i> |
|              |          | eng_dscr        | <i>e</i> | lv2         | <i>f</i> |
|              |          | guzzler         | <i>e</i> | lv4         | <i>f</i> |
|              |          |                 |          | pv2         | <i>f</i> |
|              |          |                 |          | pv4         | <i>f</i> |

*a*: data leakage (transformación directa de comb08)

*b*: específica de vehículos eléctricos o dual-fuel; no aplica a la muestra

*c*: variable derivada o versión duplicada/redondeada

*d*: identificador o metadato administrativo sin valor predictivo

*e*: alta tasa de valores faltantes o irrelevante para el objetivo del modelo

*f*: reemplazada por variable recodificada (transType, drive, gears)