



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
FACULTAD DE MATEMÁTICAS
DEPARTAMENTO DE ESTADÍSTICA
PRIMER SEMESTRE 2026

EPA Fuel Economy.

*Eficiencia de combustible a partir de las características
de un vehículo.*

EYP230I/2307 - Análisis de Regresión

Profesor: Eloy Alvarado **Ayudante:** Matías A. Pineda

Grupo 02

Integrantes:

Martín Alcántara, Gerardo Benítez, Vicente Olivares, Benjamín Vásquez

Fecha de entrega: 27 de mayo de 2026



Índice de contenido

1. Introducción	2
1.1. Contexto	2
2. Análisis exploratorio de los datos	2
2.1. Descripción de los datos	2
2.2. Limpieza de datos	5
2.3. Análisis de correlación	8
3. Plan de modelos	9
4. Modelación e Inferencia	11
5. Discusión de modelos	13
5.1. Selección	13
5.2. Significancia de los estimadores	13
5.3. Multicolinealidad	14
5.4. Relevancia de los coeficientes	15
6. Referencias bibliográficas	17
7. Anexo	18
7.1. Repositorio	18
7.2. Apéndice	18

Índice de tablas

1. Variables del modelo	3
2. Recodificación de la variable drive	5
3. Recodificación de la variable atvType	6
4. Observaciones con valores nulos en variables inesperadas	6
5. Categorías originales de trany y su clasificación	7
6. Distribución de observaciones por grupo de cilindrada (displ_grupo)	8
7. Comparativa de los tres modelos propuestos	12
8. Análisis de VIF para modelo M0	14
9. Intervalos de confianza para los coeficientes	15
10. Modelo reducido	16
11. Variables eliminadas durante la limpieza de datos	18

Índice de figuras

1. Matriz de correlación de Pearson entre variables numéricas principales.	9
--	---



1. Introducción

1.1. Contexto

Los automóviles son máquinas extremadamente complejas que transforman combustible en movimiento a través de motores. Esta transformación depende de la eficiencia de los vehículos, es decir, de cuánto combustible requieren para mover el vehículo cierta distancia o, en nuestro caso, cuánta distancia recorren por unidad fija de combustible, medida en millas por galón. Es evidente que un consumidor quiera saber qué características de un vehículo afectan más el rendimiento, ya sea para bien o para mal. Además, sabemos —por razones que discutiremos a continuación— que la cilindrada del motor es uno de los mejores indicadores del rendimiento de un vehículo. Los avances tecnológicos a través de los años también han contribuido a aumentar la eficiencia, y por estas dos razones creemos que la relación entre la cilindrada y el rendimiento depende del año del vehículo. Por ello, buscaremos investigar cuánto ha afectado el avance tecnológico el rendimiento de los autos. Adicionalmente, nos interesa comparar la eficiencia media entre fabricantes y, en el caso de modelos populares con décadas de historial de producción —como el Toyota Corolla, el Honda Civic o el Volkswagen Golf—, analizar cómo ha evolucionado su rendimiento a lo largo del tiempo.

Para entender el razonamiento detrás de nuestras aseveraciones, es necesario revisar los factores que afectan el rendimiento de un vehículo. Los más importantes suelen ser las características del motor: la cilindrada, que es el volumen total de las cámaras de combustión de los cilindros, y también el número de cilindros. Generalmente los motores se componen de varios cilindros; en los datos de este modelo el mínimo es 2, y como el volumen total es la suma de los volúmenes individuales, un vehículo con más cilindros tiende a tener mayor cilindrada. Para entender por qué más volumen implica más consumo, hay que introducir el concepto de mezcla: para que se produzca combustión se requieren combustible y oxígeno, y la relación entre ambos tiene una razón ideal de aproximadamente 15 partes de aire por 1 parte de combustible. Para mantener esa mezcla en motores de mayor volumen, se consume más combustible por ciclo, lo que reduce la eficiencia.

2. Análisis exploratorio de los datos

2.1. Descripción de los datos

El análisis comienza con una descripción de los datos disponibles para este trabajo. Primero se presentan las variables incluidas en el modelo y cómo afectan positiva o negativamente la eficiencia de un vehículo. Debido a la gran cantidad de variables presentes en los datos, las descartadas no serán explicadas en detalle, pero se listan en el apéndice junto con la razón de su exclusión.



Tabla 1
Variables del modelo

Variable	Tipo	Descripción
<i>Variable respuesta</i>		
comb08	Numérica	Rendimiento combinado (55 % ciudad + 45 % carretera) en MPG para vehículos convencionales e híbridos, y en MPGe para PHEVs.
<i>Predictores numéricos</i>		
displ	Numérica	Cilindrada del motor en litros. A mayor cilindrada, mayor consumo por ciclo.
year	Numérica	Año del modelo. Refleja mejoras tecnológicas acumuladas y estándares CAFE progresivamente más estrictos.
gears	Numérica	Número de velocidades de la transmisión. NA para CVT.
co2TailpipeGpm	Numérica	Emisiones de CO ₂ en gramos por milla. Consecuencia directa del consumo; no incluida como predictor.
<i>Predictores binarios</i>		
tCharger	Binaria	Turbocompresor presente (1) o no (0).
sCharger	Binaria	Supercompresor presente (1) o no (0).
startStop	Binaria	Tecnología start-stop presente (1) o no (0).
<i>Predictores categóricos (dummies)</i>		
drive_FWD	Binaria	Tracción delantera. Categoría de referencia: 4WD/AWD.
drive_RWD	Binaria	Tracción trasera. Categoría de referencia: 4WD/AWD.
transType_CVT	Binaria	Transmisión CVT. Categoría de referencia: Automático.
transType_Manual	Binaria	Transmisión manual. Categoría de referencia: Automático.
displ_grupo	Categórica	Cilindrada agrupada en rangos {0-2L, 2-3L, 3-4L, 4-5L, 6-7L, 7L+}. Categoría de referencia: 0-2L. Usada en M1 como alternativa categórica a displ.
<i>Variables auxiliares (no incluidas en el modelo)</i>		
atvType	Categórica	Tecnología del vehículo: Gasoline, Diesel, FFV, Hybrid, Plug-in Hybrid. Usada para filtrado.
make	Categórica	Fabricante.
model	Categórica	Nombre del modelo.
cylinders	Numérica	Número de cilindros. Altamente correlacionado con displ; se usa para la creación de la variable $displ_{per\ cyl\ necesariapara M_2}$.



A continuación se describen las demás variables de la tabla anterior. La inducción de aire al motor puede realizarse de tres maneras. La más común es la inducción natural, donde el aire entra a presión atmosférica. Para aumentar el rendimiento se han desarrollado dos tipos de inducción forzada, que introducen aire a mayor presión: los turbocargadores, que aprovechan la energía de los gases de escape para girar una turbina, y los supercargadores, que están mecánicamente vinculados al motor y usan su propia energía de rotación para comprimir el aire. En ambos casos, la inducción forzada permite inyectar más oxígeno en cada cilindro, lo que posibilita quemar más combustible y generar más potencia. El beneficio real para la eficiencia proviene de poder usar un motor más pequeño con inducción forzada para obtener la misma potencia que uno más grande de aspiración natural, aprovechando el menor consumo de los motores de menor cilindrada, llamado habitualmente *downsizing*.

Ahora que entendemos cómo se genera la rotación del motor, introduciremos los mecanismos que la transmiten en movimiento: el sistema de transmisión. Se identifican dos características principales: la tracción, que puede ser delantera, trasera o integral, y la caja de cambios, que puede ser manual, automática o CVT. La tracción delantera implica que el motor, la caja de cambios y el diferencial están en el mismo eje, lo que reduce el número de piezas y el peso del sistema, mejorando la eficiencia. La tracción trasera, en cambio, requiere un eje longitudinal adicional, lo que aumenta el peso y las pérdidas mecánicas, disminuyendo la eficiencia. La tracción integral es la más compleja y pesada de las tres, ya que debe distribuir la potencia a las cuatro ruedas a través de un sistema mecánico considerablemente más elaborado.

La caja de cambios es la segunda parte del sistema de transmisión. La más común en nuestro modelo es la transmisión automática, que históricamente era menos eficiente que la manual, pero que desde aproximadamente el año 2000 ha igualado e incluso superado su eficiencia, gracias al aumento sistemático en el número de velocidades disponibles, lo que permite al motor operar más tiempo en su rango óptimo de RPM. La transmisión manual, aunque era la más eficiente hasta los años noventa, ha perdido esa ventaja frente a los automáticos modernos. Por su parte, la transmisión CVT (*Continuously Variable Transmission*) prescinde de marchas fijas y varía la relación de transmisión de forma continua mediante un sistema de poleas y correa, manteniendo al motor siempre en su RPM de menor consumo. Es, en teoría, el tipo de transmisión con mayor potencial de eficiencia.

Por último, están los ATV (*Advanced Technology Vehicles*), que en nuestro modelo corresponden a vehículos convencionales a gasolina, diésel, híbridos, PHEV (*Plug-in Hybrid Electric Vehicle*) y FFV (*Flexible Fuel Vehicle*). Los vehículos convencionales, diésel y FFV siguen en general las ideas explicadas anteriormente, con algunas diferencias menores. El combustible diésel es aproximadamente un 15 % más energéticamente denso que la gasolina, por lo que en motores de igual tamaño tiende a producir mejor rendimiento. Los FFV están diseñados para operar con gasolina convencional o mezclas con etanol de hasta 85 % (E85); dado que el etanol tiene menor densidad energética, el rendimiento en E85 es inferior, pero en los datos se usa siempre el combustible principal recomendado por el fabricante. Los híbridos y los PHEVs combinan tracción eléctrica con mecánica y son siempre automáticos, ya que requieren un controlador electrónico para gestionar la distribución de potencia entre ambas fuentes; son los vehículos de combustión interna con mejor eficiencia por amplio margen. La comparación entre híbridos convencionales y vehículos tradicionales es directa, mientras que los PHEVs, al poder operar en modo completamente eléctrico, requieren considerar su métrica combinada (*phevComb* en MPGe) para una comparación justa.



Esta última categoría podría justificar un análisis separado.

2.2. Limpieza de datos

Para la limpieza de datos se comenzó con un análisis preliminar de las columnas según la [documentación oficial](#). Las columnas descartadas se eliminaron en dos rondas; las razones se encuentran en el apéndice. Luego de reducir el dataset de 84 descriptores a 14, se procedió a procesarlos comenzando con **tCharger**, **sCharger** y **startStop**. Estas columnas son de tipo binario, pero en los datos originales están codificadas con los valores **None**, **S**, **T** o **Y/N** para supercargadores, turbocargadores y start-stop respectivamente. Para incorporarlas al modelo de regresión se recodificaron como 0 o 1.

A continuación se procesó la variable **drive**, que representa el tipo de tracción de los vehículos. Esta columna tenía 8 categorías distintas en el dataset original, las cuales se redujeron a 3 según la siguiente tabla.

Tabla 2

*Recodificación de la variable **drive***

Categoría original (EPA)	Categoría final	<i>n</i>
Front-Wheel Drive	FWD	15.831
Rear-Wheel Drive	RWD	15.771
4-Wheel or All-Wheel Drive	4WD/AWD	6.645
All-Wheel Drive	4WD/AWD	6.580
4-Wheel Drive	4WD/AWD	2.688
2-Wheel Drive	Excluida	507
Part-time 4-Wheel Drive	Excluida	719
NaN	Excluida	1.186

Las categorías **2-Wheel Drive** y **Part-time 4-Wheel Drive** fueron excluidas por ser minoritarias, corresponder en su mayoría a vehículos antiguos y no ajustarse a la clasificación estándar del modelo. Junto con los registros sin valor en **drive**, las filas eliminadas en este paso representan el 4,8 % del total de observaciones originales, por lo que el efecto sobre la representatividad es mínimo en comparación con la interpretabilidad que aporta este paso.

Para el procesamiento de **atvType** se identificaron las categorías presentes en la fuente, que se muestran en la siguiente tabla.



Tabla 3

Recodificación de la variable `atvType`

Categoría original (EPA)	Categoría final	<i>n</i>
NaN	Gasoline	43.325
Diesel	Diesel	1.238
Hybrid	Hybrid	1.805
FFV	FFV	1.538
Plug-in Hybrid	Plug-in Hybrid	442
EV	Excluida	1.457
CNG	Excluida	50
FCV	Excluida	42
Bifuel (CNG)	Excluida	20
Bifuel (LPG)	Excluida	8
eFCV	Excluida	2

Los vehículos convencionales a gasolina no tienen valor en `atvType` en los datos originales; se les asignó la etiqueta **Gasoline** para claridad. Las categorías excluidas corresponden a vehículos eléctricos puros, de gas natural, de hidrógeno o de combustible dual, que no son directamente comparables con vehículos de combustión interna en términos de MPG. En conjunto representan el 3,2 % de las observaciones originales, por lo que su exclusión tiene un efecto mínimo sobre la representatividad del dataset.

Tras completar la limpieza de las variables categóricas, se verificó si quedaban filas con valores nulos. Se encontraron 3 registros con valores faltantes en `cylinders` y/o `displ`, correspondientes a 2 modelos distintos.

Tabla 4

Observaciones con valores nulos en variables inesperadas

Idx	make	model	year	cylinders	displ	drive	trany
21410	Subaru	RX Turbo	1985	NaN	NaN	4WD/AWD	Manual 5-spd
21411	Subaru	RX Turbo	1985	NaN	NaN	4WD/AWD	Manual 5-spd
21500	Mazda	RX-7	1986	NaN	1.3	RWD	Manual 5-spd

Los tres registros tienen valores nulos en `cylinders` o `displ` por registros incompletos en la fuente EPA. El valor faltante del Mazda RX-7 (índice 21500) fue corregido manualmente consultando otros años del mismo modelo en el dataset. Los dos registros del Subaru RX Turbo (índices 21410–21411), al no contar con información suficiente para imputar, se eliminaron mediante `dropna()`.

Con los datos libres de valores faltantes y las categorías correctamente identificadas, se procedió a codificar `trany` y `drive`. La codificación de `trany` requirió un procesamiento previo, ya que esta columna combina el tipo de transmisión y el número de velocidades en un mismo campo. La Tabla 5 muestra los tipos de transmisión presentes en los datos y su clasificación.



Tabla 5

Categorías originales de `trany` y su clasificación

Categoría original (EPA)	Clasificación	<i>n</i>
<i>Manual</i>		
Manual 3-spd	Manual	77
Manual 4-spd	Manual	1.483
Manual 4-spd Doubled	Manual	17
Manual 5-spd	Manual	8.392
Manual 6-spd	Manual	3.138
Manual 7-spd	Manual	182
<i>Automático</i>		
Automatic 3-spd	Automatic	3.151
Automatic 4-spd	Automatic	11.048
Automatic 5-spd	Automatic	2.203
Automatic 6-spd	Automatic	1.758
Automatic 7-spd	Automatic	720
Automatic 8-spd	Automatic	1.141
Automatic 9-spd	Automatic	875
Automatic 10-spd	Automatic	517
Automatic (S4--S10)	Automatic	3.705
Automatic (AM5--AM8)	Automatic	584
Automatic (AM-S6--AM-S10)	Automatic	1.300
Automatic (A1), (A2)	Automatic	1.495
Automatic (L3), (L4)	Automatic	4
<i>CVT</i>		
Automatic (variable gear ratios)	CVT	1.203
Automatic (AV-S1)	CVT	46
Automatic (AV-S6)	CVT	376
Automatic (AV-S7)	CVT	224
Automatic (AV-S8)	CVT	226
Automatic (AV-S10)	CVT	67
NaN	Excluida	11

Las categorías **Automatic (SX)** corresponden a transmisiones automáticas con modo secuencial de X velocidades (cambios manuales mediante paletas o palanca). Las **AM** y **AM-S** son transmisiones automáticas de doble embrague. Las **AV** son variantes de CVT con relaciones virtuales reportadas. La clasificación se realizó según si el nombre contiene **variable gear ratios** o **AV** (CVT), comienza con **Manual** (Manual), o en caso contrario (Automático).

A partir de `trany` se extrajeron dos columnas nuevas: **transType**, con el tipo de transmisión, y **gears**, con el número de velocidades. Para las transmisiones CVT, **gears** se dejó como NaN, ya que el número de velocidades no es comparable con el de transmisiones de marchas fijas. Esto implica que posiblemente sea necesario tratar estos vehículos en una regresión separada para analizar el efecto de esta tecnología sobre la eficiencia. Algo similar podría ocurrir con los PHEVs, lo que se discutirá más adelante.

Para establecer una base común de comparación entre vehículos PHEV y convencionales, se reemplazó `comb08` por `phevComb` en los registros con `atvType = Plug-in Hybrid`. La columna `phevComb` refleja la



eficiencia en modo combinado (eléctrico y gasolina) de los PHEVs, mientras que `comb08` registra únicamente el modo convencional sin asistencia eléctrica. Dado que precisamente esa asistencia es el beneficio que caracteriza a estos vehículos y parte de lo que se busca estudiar, `phevComb` es la métrica más adecuada. Para construir las categorías descritas en la Tabla 1 para M_1 , se agruparon las cilindradas considerando que los vehículos con menos de 2 litros tienden a corresponder a autos económicos, y luego se fueron agrupando en intervalos de 1 litro, dejando los vehículos de más de 7 litros de cilindrada agrupados juntos, ya que estos son poco comunes. Las cantidades por grupo se resumen en la Tabla 6.

Tabla 6

Distribución de observaciones por grupo de cilindrada (`displ_grupo`)

Grupo	n	%
0–2L	11447	24.9
2–3L	14334	31.2
3–4L	8629	18.8
4–5L	5557	12.1
5–6L	4497	9.8
6–7L	1487	3.2
7L+	61	0.1
Total	46012	100.0

Finalmente, se codificaron `transType` y `drive` como variables dummy. Tras eliminar `trans` y `phevComb`, el dataset quedó con las 16 columnas presentadas al inicio del análisis exploratorio. Cabe mencionar que `make` y `model` no fueron codificadas, ya que generarían más de 1.000 variables dummy dado el número de marcas y modelos distintos presentes en los datos. Se optó por mantenerlas durante todo el proceso de limpieza para conservar la trazabilidad de los registros excluidos y porque, más adelante en la metodología, se utilizarán para agrupar o filtrar por marca y modelo en los análisis propuestos.

2.3. Análisis de correlación

Para evaluar colinealidad entre los predictores numéricos se calculó la matriz de correlación de Pearson (Figura 1). Se observa una correlación muy alta entre `displ` y `cylinders` ($r = 0.90$), lo que indica que ambas variables capturan esencialmente la misma información sobre el tamaño del motor. Por esta razón, `cylinders` no se incluye como predictor independiente en ningún modelo, sino que se utiliza únicamente para construir `displ_per_cyl` (Modelo M_2), cuya correlación con `cylinders` es considerablemente menor ($r = 0.39$).




Imagen 1

Matriz de correlación de Pearson entre variables numéricas principales.

3. Plan de modelos

Para llevar a cabo el análisis propuesto en la pregunta de investigación, decidimos proponer 3 modelos candidatos. Estos modelos los construimos a partir del análisis y conocimiento previamente descritos sobre este tema, y buscan, con la información disponible, definir de 3 maneras distintas el fenómeno que queremos estudiar.

Estos modelos son los siguientes:



$$\begin{aligned} M_0 : \text{comb08} = & \beta_0 + \beta_1 \text{displ} + \beta_2 \text{year} + \beta_3 (\text{displ} \cdot \text{year}) \\ & + \beta_4 \text{gears} + \beta_5 \text{tCharger} + \beta_6 \text{sCharger} + \beta_7 \text{startStop} \\ & + \beta_8 \text{FWD} + \beta_9 \text{RWD} + \beta_{10} \text{Manual} + \epsilon \end{aligned}$$

$$\begin{aligned} M_1 : \text{comb08} = & \beta_0 + \beta_1 \text{displ}_{2-3L} + \beta_2 \text{displ}_{3-4L} + \beta_3 \text{displ}_{4-5L} \\ & + \beta_4 \text{displ}_{5-6L} + \beta_5 \text{displ}_{6-7L} + \beta_6 \text{displ}_{7L+} + \beta_7 \text{year} \\ & + \beta_8 (\text{displ}_{2-3L} \cdot \text{year}) + \beta_9 (\text{displ}_{3-4L} \cdot \text{year}) + \beta_{10} (\text{displ}_{4-5L} \cdot \text{year}) \\ & + \beta_{11} (\text{displ}_{5-6L} \cdot \text{year}) + \beta_{12} (\text{displ}_{6-7L} \cdot \text{year}) + \beta_{13} (\text{displ}_{7L+} \cdot \text{year}) \\ & + \beta_{14} \text{gears} + \beta_{15} \text{tCharger} + \beta_{16} \text{sCharger} + \beta_{17} \text{startStop} \\ & + \beta_{18} \text{FWD} + \beta_{19} \text{RWD} + \beta_{20} \text{Manual} + \epsilon \end{aligned}$$

$$\begin{aligned} M_2 : \text{comb08} = & \beta_0 + \beta_1 \text{displ_per_cyl} + \beta_2 \text{year} + \beta_3 (\text{displ_per_cyl} \cdot \text{year}) \\ & + \beta_4 \text{startStop} + \beta_5 \text{gears} + \beta_6 \text{tCharger} + \beta_7 \text{sCharger} \\ & + \beta_8 \text{RWD} + \beta_9 \text{FWD} + \beta_{10} \text{Manual} + \epsilon \end{aligned}$$

Para todos los modelos dejamos fuera las variables auxiliares de la Tabla 1. El modelo M_0 representa la versión más simple de nuestros supuestos: incluye las variables identificadas en el EDA como relevantes para la eficiencia de un vehículo, junto con la interacción $\text{displ} * \text{year}_c$, que captura nuestra pregunta central — si la mejora de eficiencia en el tiempo difiere según el tamaño del motor.

El modelo M_1 representa la misma idea, pero en lugar de utilizar la cilindrada de los vehículos de manera continua, esta se representa como categorías de segmentos de volumen del motor, como se especificó en la Tabla 1. Esta decisión se tomó dado que la distribución de displ está altamente concentrada en motores de hasta 4L, que representan $\approx 74.8\%$ de los datos. El problema de una especificación continua, como en M_0 , es que se estima una única pendiente para displ y para su interacción con year_c , y ambas quedan dominadas por este segmento. Para poder evaluar si la linealidad global es razonable, o si hay segmentos menos representados que se comportan de manera distinta, el modelo M_1 propone tratar la interacción $\text{displ} * \text{year}_c$ de manera categórica, separada para cada categoría de cilindrada, permitiendo que cada segmento se ajuste de forma independiente a la tendencia de los vehículos más comunes.

Finalmente, el modelo M_2 representa una aproximación distinta: displ mezcla dos dimensiones, la cantidad de cilindros y el volumen por cilindro, las cuales están altamente correlacionadas ($r = 0.90$, Figura 1), por lo que no pueden incluirse como predictores independientes sin generar colinealidad severa. Para aislar el tamaño por cilindro, se construye la variable $\text{displ_per_cyl} = \text{displ}/\text{cylinders}$, interactuada con year_c . Esto permite evaluar si la tendencia temporal en eficiencia se explica mejor por el tamaño promedio de cada cilindro —dimensión asociada a la tendencia de *downsizing* con inducción forzada— que por la cilindrada total o agrupada.



4. Modelación e Inferencia

Con el fin de verificar las hipótesis planteadas por los tres modelos, se desarrolla y ejecuta un script de R. En particular, los modelos de regresión de la forma $Y \sim X\beta + \varepsilon$ se trabajan con la función `lm` propia del lenguaje. Por ejemplo, un modelo $M_\varphi : \text{comb08} = \beta_0 + \beta_1 \text{displ}$, según los datos `df_filtered`, se ejecutaría con el comando `lm(comb08 ~ displ, data = df_filtered)`.

Los resultados de los tres modelos se resumen en la Tabla 7. En particular, notamos que todos los coeficientes resultan significativos. Esto se ve explicado, principalmente, por el elevado número de datos utilizados en el cálculo de la regresión. Se realiza un estudio más detallado en las secciones posteriores.

Cabe destacar que para todos los modelos se centraron los años. Esto se hace para controlar el efecto arbitrario generado por el año absoluto. En particular, se observaba una correlación muy elevada entre las variables `displ`, con `displ:year` (y sus respectivas formas en los modelos **M1** y **M2**, debido a que `displ:year` $\approx 2000\text{displ}$).



Tabla 7
Comparativa de los tres modelos propuestos

Parámetros	M0	M1	M2
<i>Estimadores compartidos</i>			
(Intercept)	24.989*	22.683*	29.110*
year_c	0.182*	0.130*	0.283*
gears	0.332*	0.284*	0.038+
tCharger	-1.084*	-1.716*	-0.457*
sCharger	-0.622*	-0.948*	-1.254*
startStop	1.325*	1.234*	2.070*
drive_FWD	3.321*	3.165*	4.707*
drive_RWD	0.827*	0.746*	0.301*
transType_Manual	0.572*	0.446*	1.519*
<i>Efecto individual</i>			
displ	-2.399*		
displ × year_c	-0.027*		
displ_grupo2-3L		-4.359*	
displ_grupo2-3L × year_c		-0.011*	
displ_grupo3-4L		-6.891*	
displ_grupo3-4L × year_c		-0.033*	
displ_grupo4-5L		-8.435*	
displ_grupo4-5L × year_c		-0.088*	
displ_grupo5-6L		-10.057*	
displ_grupo5-6L × year_c		-0.040*	
displ_grupo6-7L		-9.418*	
displ_grupo6-7L × year_c		-0.180*	
displ_grupo7L+		-12.514*	
displ_grupo7L+ × year_c		-0.123**	
displ_per_cyl			-20.049*
displ_per_cyl × year_c			-0.309*
<i>Métricas</i>			
R2	0.662	0.679	0.523
R2 Ajustado	0.662	0.679	0.523
AIC	222 527.0	220 235.6	237 611.6
BIC	222 631.3	220 426.8	237 715.9
RMSE	3.045 275	2.966 204	3.615 697
Número de Observaciones	43 929	43 929	43 929
+ p < 0.1	* p < 0.05	* p < 0.01	** p < 0.001

Se reportan los resultados principales del análisis de varianza realizado sobre los tres modelos. En particular, se separa la tabla en tres secciones. Primero, se reportan los coeficientes asociados a estimadores presentes en los tres modelos. Segundo, se reportan los efectos específicos propuestos según cada modelo. Tercero, se reportan métricas de interés de los modelos para un análisis comparativo posterior.



5. Discusión de modelos

5.1. Selección

Hasta el momento, hemos trabajado con tres distintos modelos. Estos tres modelos son idénticos a excepción de la manera en que se identifica y trabaja el efecto del volumen del motor, y su relación con el año de los vehículos. En esta sección buscaremos discutir, en base a las pruebas realizadas, la pertinencia de los distintos modelos, con el objetivo de seleccionar el mejor modelo, o aquel que busquemos defender. Observando los resultados en la Tabla 7, se puede rápidamente descartar el modelo **M2**, debido a tener un desempeño notoriamente inferior en todas las métricas utilizadas. En particular, notamos que el valor de R_{adj}^2 es de 0.523 para este modelo, mientras que para los modelos **M0** y **M1** se tienen valores de 0.662 y 0.679 respectivamente. Por otro lado, la comparativa entre **M0** y **M1** requiere mayor atención. En estricto rigor, el modelo **M1** tiene un mejor desempeño de manera transversal. Sin embargo, este incremento es marginal, en especial al compararlo con el modelo **M2**. Por ende, es necesario determinar si esta mejora es suficientemente significativa para justificar la reducción en la interpretabilidad de los resultados. Esto es, el modelo **M0** es tratado como valor numérico y, por ende, el valor de los coeficientes asociados a esta variable tiene una interpretación sencilla y directa en un sentido físico. Tomando como ejemplo el efecto de la columna `displ`, notamos que se obtiene un valor de -2.399 . Esto es, cuando el volumen del motor aumenta en 1 litro, la eficiencia del vehículo disminuye por, aproximadamente, 2.4 millas por galón de combustible. Este nivel de interpretación se vuelve más trabajoso al utilizar el modelo **M1**. Al ser una variable categórica, el efecto asociado refiere a la tendencia que tiene según la inclusión a cierto grupo. Esto es, el coeficiente asociado a cada grupo de la tabla representa la pérdida de eficiencia al pertenecer a dicho grupo, utilizando como base el grupo de vehículos con volumen de motor menor a 2 litros. Si bien este análisis tiene sus beneficios, esto requiere un conocimiento previo mayor, y no aporta información sustancialmente distintiva, considerando que se puede observar una tendencia decreciente en los grupos, como predicho por el modelo **M0**. De esta manera, determinamos más relevante el modelo **M0**, y es con este el que buscaremos seguir trabajando.

5.2. Significancia de los estimadores

Como mencionado anteriormente, los estimadores observados en la Tabla 7 tienen todos un alto nivel de significancia. En particular, los resultados reportados por la tabla ANOVA nativa de R se observan, en su mayoría, como $< 2e^{-16}$, con algunas pocas excepciones. Esto resulta alarmante, pero es un comportamiento totalmente esperado en base al número de observaciones presentes en el análisis, debido a que el valor-p está relacionado al número de comparaciones según $p \propto \frac{1}{\sqrt{n}}$. En otras palabras, toda diferencia, sin importar cuan marginal pueda ser, se ve dilatada y exagerada al ser observada de manera repetida. Esto no tiene solución, debido al no ser estrictamente un error del modelo. Pero sí significa que se requiere considerar otras métricas o métodos de análisis.



5.3. Multicolinealidad

Recordamos que el modelo actual está dado por

$$\begin{aligned} M_0 : \text{comb08} = & \beta_0 + \beta_1 \text{displ} + \beta_2 \text{year} + \beta_3 (\text{displ} \cdot \text{year}) \\ & + \beta_4 \text{gears} + \beta_5 \text{tCharger} + \beta_6 \text{sCharger} + \beta_7 \text{startStop} \\ & + \beta_8 \text{FWD} + \beta_9 \text{RWD} + \beta_{10} \text{Manual} + \epsilon. \end{aligned}$$

Además, reiteramos que esta relación define la interacción de variables físicas, en su efecto de la eficiencia de combustible para un determinado vehículo. De esta manera, es imperativo realizar un análisis de multicolinealidad de las variables consideradas. Esto puesto que, al considerar una gran cantidad de atributos de un vehículo, sería posible que el efecto de algunas estén más correlacionadas de lo esperado. En base a ello, se realiza un análisis de VIF, cuyos resultados se observan en la Tabla 8. Notamos que, en su mayoría, los resultados no indican multicolinealidad, con la excepción de las variables asociadas al año, como se observa en la primera parte de la tabla. La segunda parte de la tabla corrobora nuestra hipótesis; al eliminar el efecto del año, se reduce la multicolinealidad del modelo. La variable **gears** aún presenta un VIF ligeramente elevado, pero se decide no intervenir para este, debido a su efecto físico en el uso eficiente del vehículo.

Tabla 8

*Análisis de VIF para modelo **M0***

Coeficiente	VIF
<i>Considerando year_c</i>	
displ	1.621
year_c	8.447
gears	3.986
tCharger	1.658
sCharger	1.041
startStop	2.102
drive_FWD	1.817
drive_RWD	1.446
transType_Manual	1.247
displ:year_c	7.191
<i>Sin considerar year_c</i>	
displ	1.617
gears	3.782
tCharger	1.598
sCharger	1.041
startStop	2.077
drive_FWD	1.815
drive_RWD	1.445
transType_Manual	1.212
displ:year_c	2.752

Se reportan los resultados de la prueba VIF para el modelo **M0**, incluyendo y excluyendo el efecto individual del año.



5.4. Relevancia de los coeficientes

Hasta el momento hemos trabajado con el modelo completo incluyendo todas sus variables. Recordamos, sin embargo, que si bien los estimadores tienen alta significancia estadística, esto no nos asegura que tengan un efecto sustancial en la eficiencia final del vehículo. Para ello, se hace uso de la librería `effectsize` de R. Con ella, podemos estandarizar los coeficientes y obtener su intervalo de confianza, representado en la Tabla 9.

Con ello, se observa que algunos parámetros muestran un efecto bastante reducido. Por ende, se propone realizar una prueba de modelos anidados para ambas direcciones. Esto es, a partir de cierta métrica, buscamos incluir y eliminar iterativamente variables hasta que no se encuentre un efecto significativo. Esto se prueba inicialmente con la prueba de F parcial, pero con ella se retorna al modelo completo. Esto puesto que los valores de F parcial para toda variable, en toda iteración, es altamente elevado, cuya interpretación es nuevamente el elevado número de observaciones.

Por ende, se programa una función para realizar estas pruebas con el incremento parcial de R_{adj}^2 , debido a poseer una cota superior, y tener alta relevancia e interpretación para el caso. Utilizando un incremento de entrada de 0.004, y decrecimiento de salida de 0.001, y fijando los efectos de `displ` y `displ_year_c`, obtenemos el modelo reducido a los efectos de `displ`, `displ:year_c`, `drive_FWD` y `gears`, cuyos resultados se resumen en la Tabla 10. Notamos que para este modelo reducido, todos los interceptos tienen un efecto sustancial, y el R_{adj}^2 obtuvo una disminución marginal con respecto al modelo completo.

De esta manera, proponemos este como el modelo final a utilizar, codificando de manera robusta y significativa el efecto de la eficiencia del vehículo.

Tabla 9

Intervalos de confianza para los coeficientes

Parametro	Coefficiente Estandarizado	Intervalo de confianza (95 %)
(Intercept)	0.00	[0.00, 0.00]
<code>displ</code>	-0.62	[-0.62, -0.61]
<code>year_c</code>	0.43	[0.41, 0.45]
<code>gears</code>	0.10	[0.09, 0.12]
<code>tCharger</code>	-0.09	[-0.10, -0.08]
<code>sCharger</code>	-0.02	[-0.02, -0.01]
<code>startStop</code>	0.09	[0.09, 0.10]
<code>drive FWD</code>	0.30	[0.29, 0.30]
<code>drive RWD</code>	0.08	[0.07, 0.08]
<code>transType_Manual</code>	0.05	[0.04, 0.06]
<code>displ × year_c</code>	-0.22	[-0.23, -0.21]

Se reportan los intervalos de confianza para los coeficientes.



Tabla 10
Modelo reducido

Parámetros	M0 reducido
<i>Estimadores compartidos</i>	
(Intercept)	23.339 878 7*
gears	0.700 852 4*
drive_FWD	2.843 874 0*
displ	−2.347 622 0*
displ × year_c	0.008 702 2*
R2 Ajustado	0.6297
+ p < 0.1 * p < 0.05 * p < 0.01 ** p < 0.001	

Se reportan los resultados del modelo reducido.



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
FACULTAD DE MATEMÁTICAS
DEPARTAMENTO DE ESTADÍSTICA

6. Referencias bibliográficas

U.S. Department of Energy and U.S. Environmental Protection Agency. (2026). Fuel economy data.
<https://www.fueleconomy.gov/feg/download.shtml>.



7. Anexo

7.1. Repositorio

La totalidad de los códigos utilizados para la limpieza de los datos, el análisis, y modelamiento, será almacenado en un [repositorio de github](#).

Este repositorio está organizado separando los datos, y códigos utilizados en su preprocesamiento en una carpeta, y los códigos asociados al análisis de regresión en otro. El desarrollo de estos códigos es de desarrollo y uso exclusivo e independiente por los integrantes del grupo, en línea a los datos de la EPA según el proyecto "Fuel Economy", para efectos académicos.

7.2. Apéndice

Tabla 11

Variables eliminadas durante la limpieza de datos

Variable	Razón	Variable	Razón	Variable	Razón
city08	<i>a</i>	combA08	<i>b</i>	cityCD	<i>c</i>
highway08	<i>a</i>	cityA08	<i>b</i>	highwayCD	<i>c</i>
barrels08	<i>a</i>	highwayA08	<i>b</i>	combinedCD	<i>c</i>
barrelsA08	<i>a</i>	combA08U	<i>b</i>	cityUF	<i>c</i>
fuelCost08	<i>a</i>	cityA08U	<i>b</i>	highwayUF	<i>c</i>
fuelCostA08	<i>a</i>	highwayA08U	<i>b</i>	combinedUF	<i>c</i>
youSaveSpend	<i>a</i>	combE	<i>b</i>	phevBlended	<i>c</i>
feScore	<i>a</i>	cityE	<i>b</i>	charge120	<i>c</i>
ghgScore	<i>a</i>	highwayE	<i>b</i>	charge240	<i>c</i>
ghgScoreA	<i>a</i>	co2A	<i>b</i>	charge240b	<i>c</i>
comb08U	<i>d</i>	co2TailpipeAGpm	<i>b</i>	c240Dscr	<i>c</i>
city08U	<i>d</i>	fuelType2	<i>b</i>	c240bDscr	<i>c</i>
highway08U	<i>d</i>	UCityA	<i>b</i>	range	<i>c</i>
co2	<i>d</i>	UHighwayA	<i>b</i>	rangeCity	<i>c</i>
trany	<i>d</i>	phevCity	<i>d</i>	rangeHwy	<i>c</i>
trans_dscr	<i>d</i>	phevHwy	<i>d</i>	rangeA	<i>c</i>
fuelType	<i>d</i>	id	<i>e</i>	rangeCityA	<i>c</i>
fuelType1	<i>d</i>	engId	<i>e</i>	rangeHwyA	<i>c</i>
baseModel	<i>d</i>	mfrCode	<i>e</i>	evMotor	<i>c</i>
UCity	<i>d</i>	createdOn	<i>e</i>	VClass	<i>f</i>
UHighway	<i>d</i>	modifiedOn	<i>e</i>	hlv	<i>f</i>
		mpgData	<i>e</i>	hpy	<i>f</i>
		eng_dscr	<i>e</i>	lv2	<i>f</i>
		guzzler	<i>e</i>	lv4	<i>f</i>
				pv2	<i>f</i>
				pv4	<i>f</i>

a: data leakage (transformación directa de comb08)

b: específica de vehículos eléctricos o dual-fuel; no aplica a la muestra

c: variable derivada o versión duplicada/redondeada

d: identificador o metadato administrativo sin valor predictivo

e: alta tasa de valores faltantes o irrelevante para el objetivo del modelo

f: reemplazada por variable recodificada (transType, drive, gears)